# Domestic Scaled Company

Data: Tech Company Fundings (since 2020)

## Contents

- A1. Data 설명: 2020년 이후 투자 받은 Tech Company
- A2. 원본 데이터 확인
- **BO.** EDA 및 Data Wrangling
- **B1.** EDA 및 데이터 전처리
- **B2.** Data Wrangling 1. Region
- **B3.** Data Wrangling 2. Field(Verticle)
- **B4.** Data Wrangling 3. Funding Stage
- + Company Insight
- C1. Target 분포
- C2. Data Leakage
- **C3.** 모델링
- **C4.** 최종 모델 학습
- C5. 모델 해석

## A1. Data: 2020년 이후 투자 받은 Tech company

	df_index	Сомрап	y Website	Region	Vertical	Funding Amount (USD)	Funding Stage	Funding Date
0	1	Intern	t https://internxt.com/	Spain	Blockchain	278940	Seed	Jan-20
1	2	Dockflo	w https://dockflow.com	Belgium	Logistics	292244	Seed	Jan-20

#### A2. 원본 데이터 확인 (3575, 8)

**Company (3224)** 

Website (3343)

Region (7

2

Vertical (143)

Funding Stage (22)

### 원본 데이터 확인

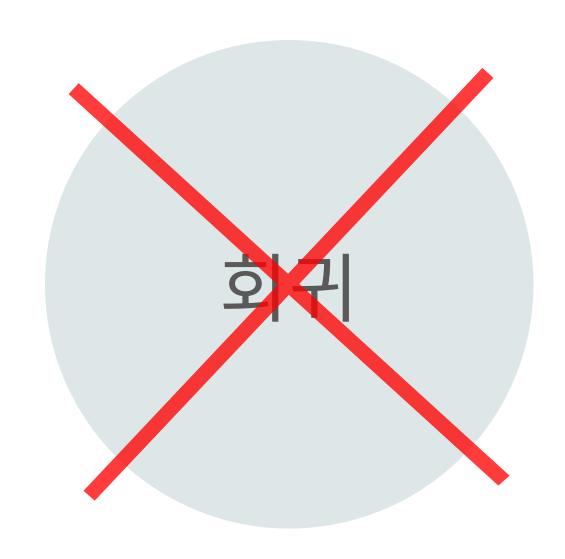
	count	un i que	top	freq
Funding Date	3575	19	May-21	332
Funding Stage	3575	22	Series A	951
Region	3563	72	United States	2034
Vertical	3575	143	B2B Software	632
Funding Amount (USD)	3575	969	10000000	105
Company	3575	3224	Internxt	4
Website	3575	3343	https://humaninterest.com/	4

#### Warnings

Company has a high cardinality: 3224 distinct values	High cardinality
Website has a high cardinality: 3343 distinct values	High cardinality
Region has a high cardinality: 72 distinct values	High cardinality
Vertical has a high cardinality: 143 distinct values	High cardinality
Funding Amount (USD) has a high cardinality: 969 distinct values	High cardinality
df_index has unique values	Unique

### 원본 데이터 확인

Funding Amount(USD), Funding Date 를 제외하고 카테고리형



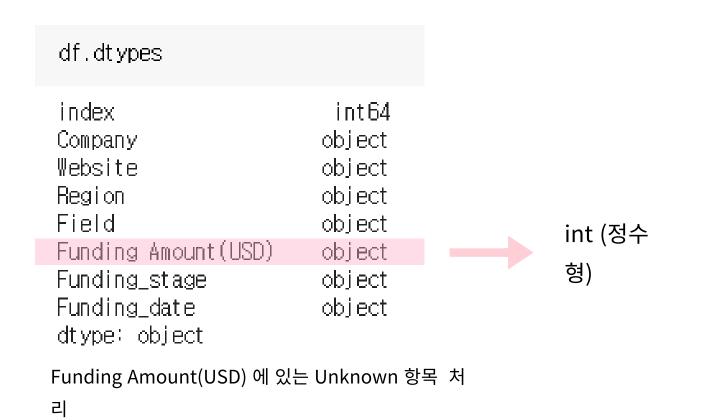


## EDA / Data Wrangling

#### B1. EDA 및 데이터 전처리\_1

- 1. Column 명 변경
- 2. 결측치 확인 (가시적/ 비가시적)

```
[(x,df[x].isnull().sum()) for x in df.columns if df[x].isnull().any()]
[('Region', 12)]
```



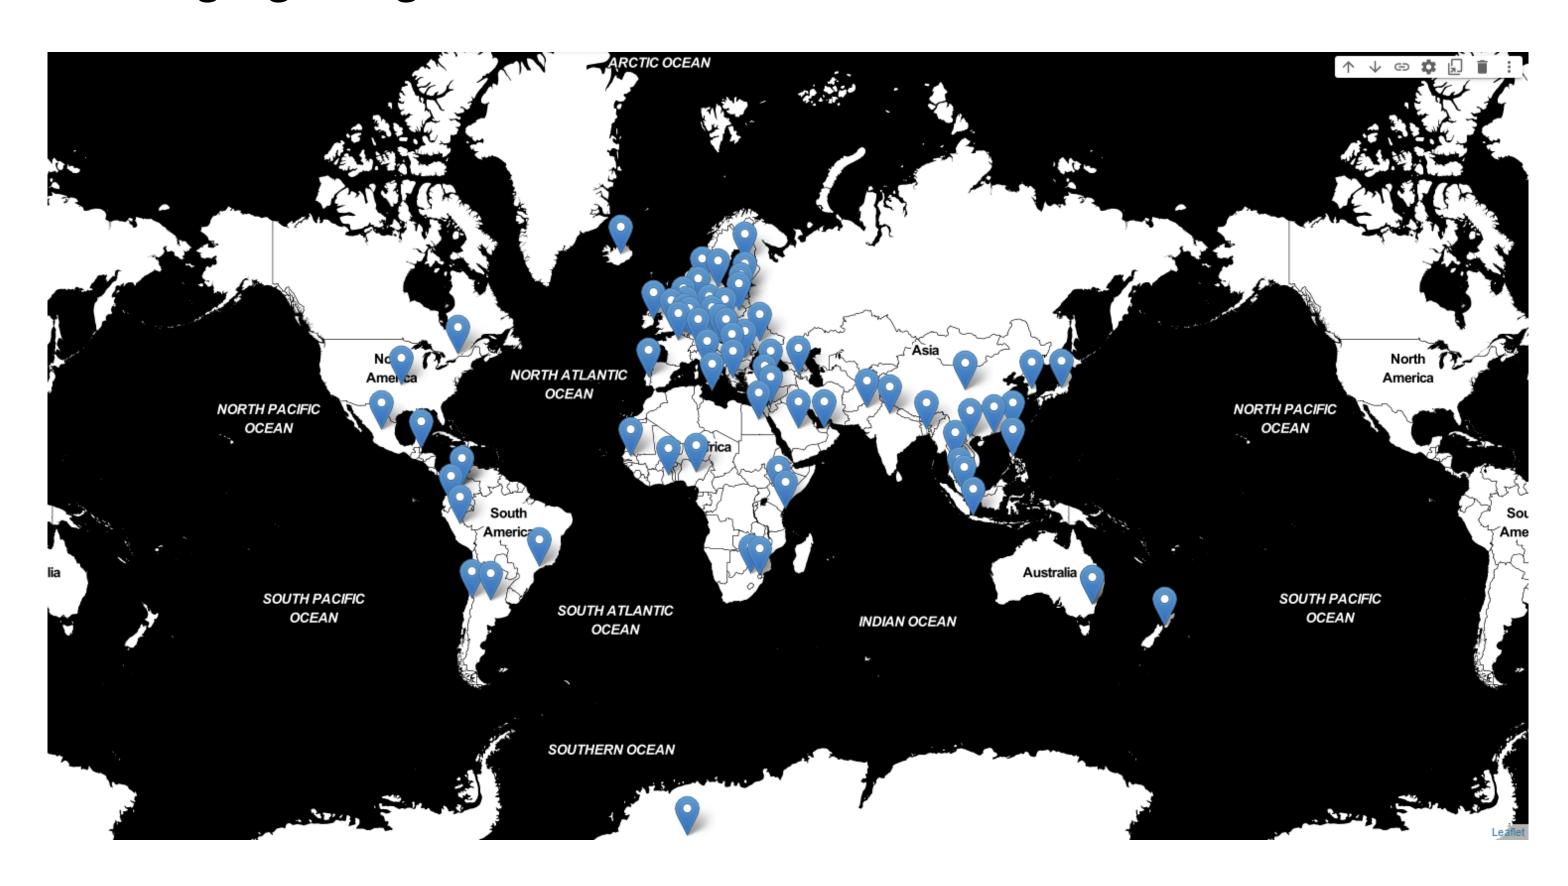
df.isna().sum() # 형 변환을 시켜줬더니 드러나지 않았던 결측치가 드러남 index Company Website 12 Region Field 9 Funding Amount(USD) Funding\_stage Funding\_date dtype: int64

#### 결측치의 양이 적으므로 fillna()를 통해 결측치를 대체

	index	Funding Amount(USD)
count	3575.00	3566.00
mean	1788.00	57560141.00
std	1032.16	298197613.73
min	1.00	40000.00
25%	894.50	5000000.00
50%	1788.00	15496301.50
75%	2681.50	50000000.00
max	3575.00	16600000000.00

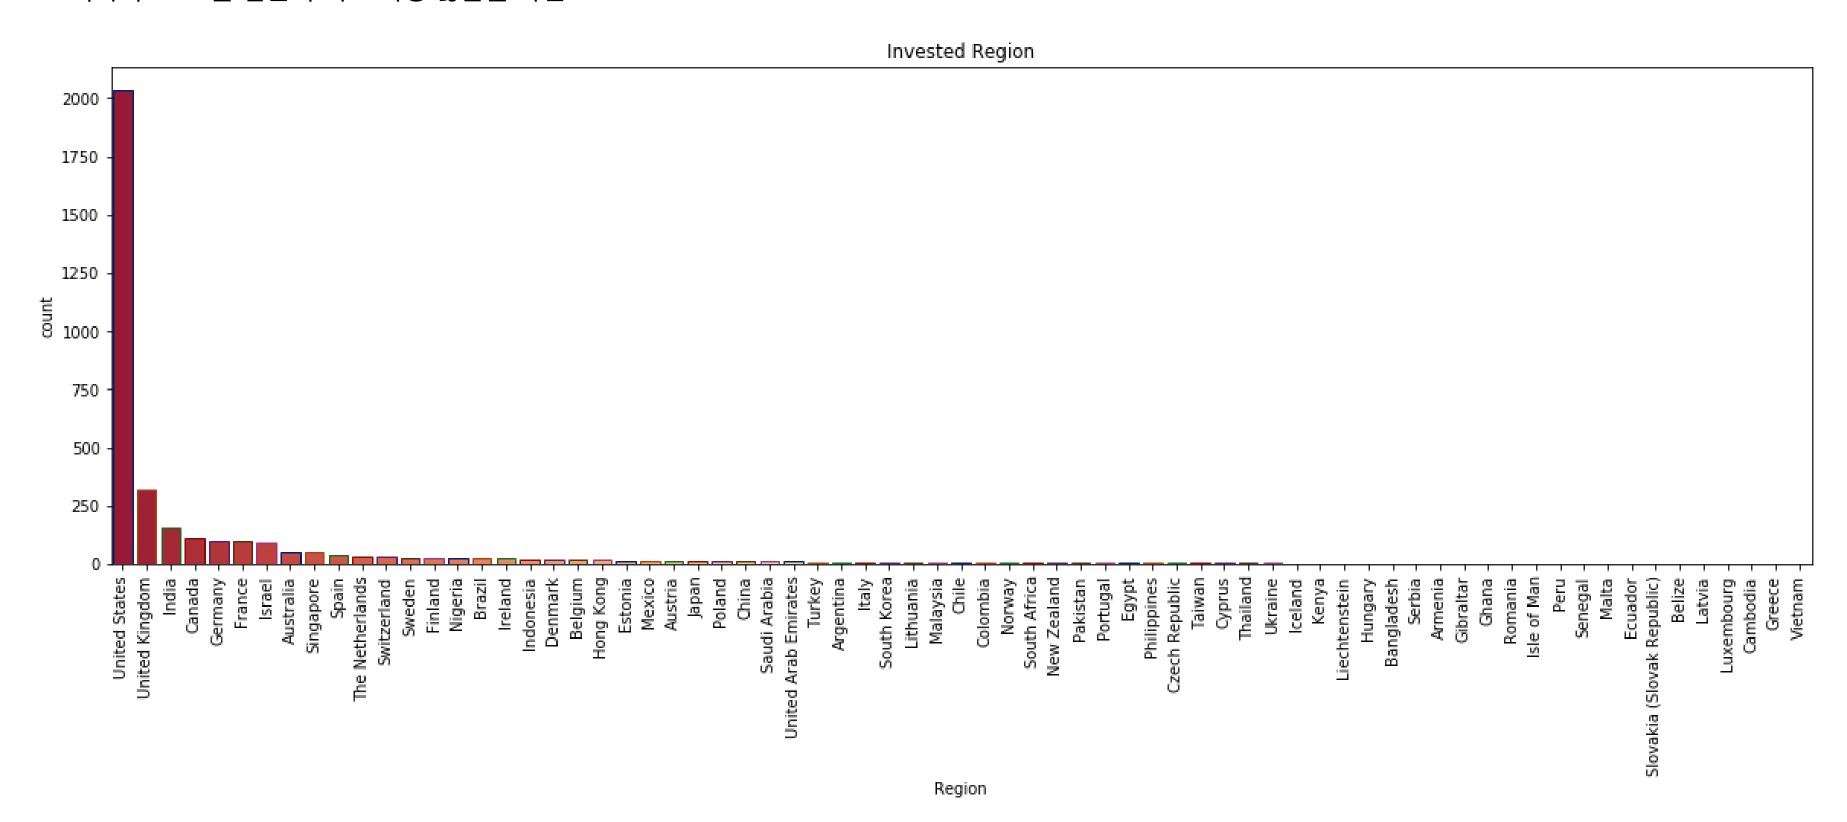
- 3. Funding Date 전처리
- 4. index, Website 열 제거

## **B2.** Data wrangling 1. Region



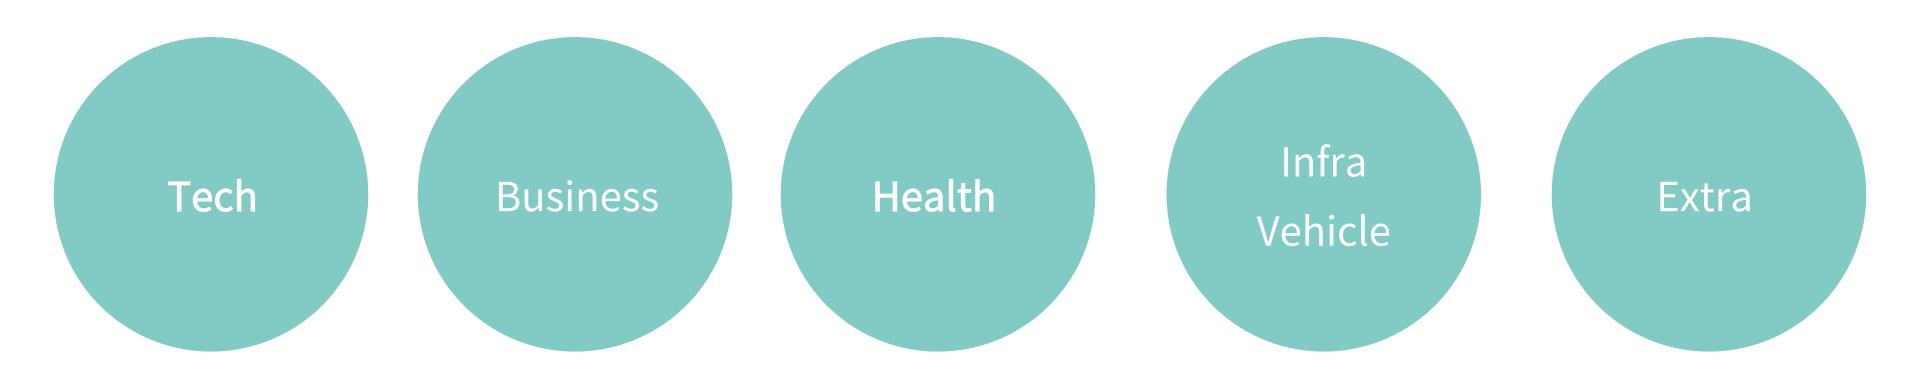
#### 투자 받은 국가

미국이 2000을 넘는 수치로 가장 많음을 확인



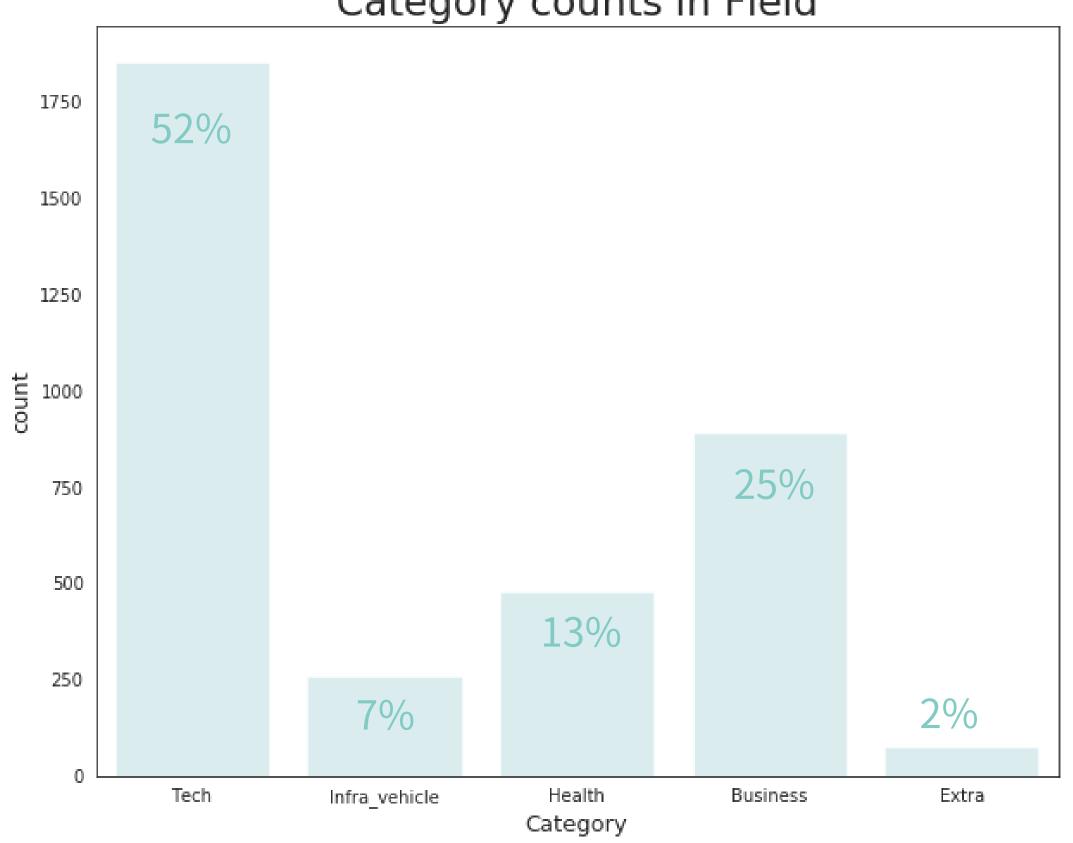
## B3. Data wrangling 2. Field (Verticle)

- 143개 영역을 5개 범주로 카테고리화
- 사용하지 않을 Field(Verticle) 제거



## Categorize한 Field(Verticle) 분포

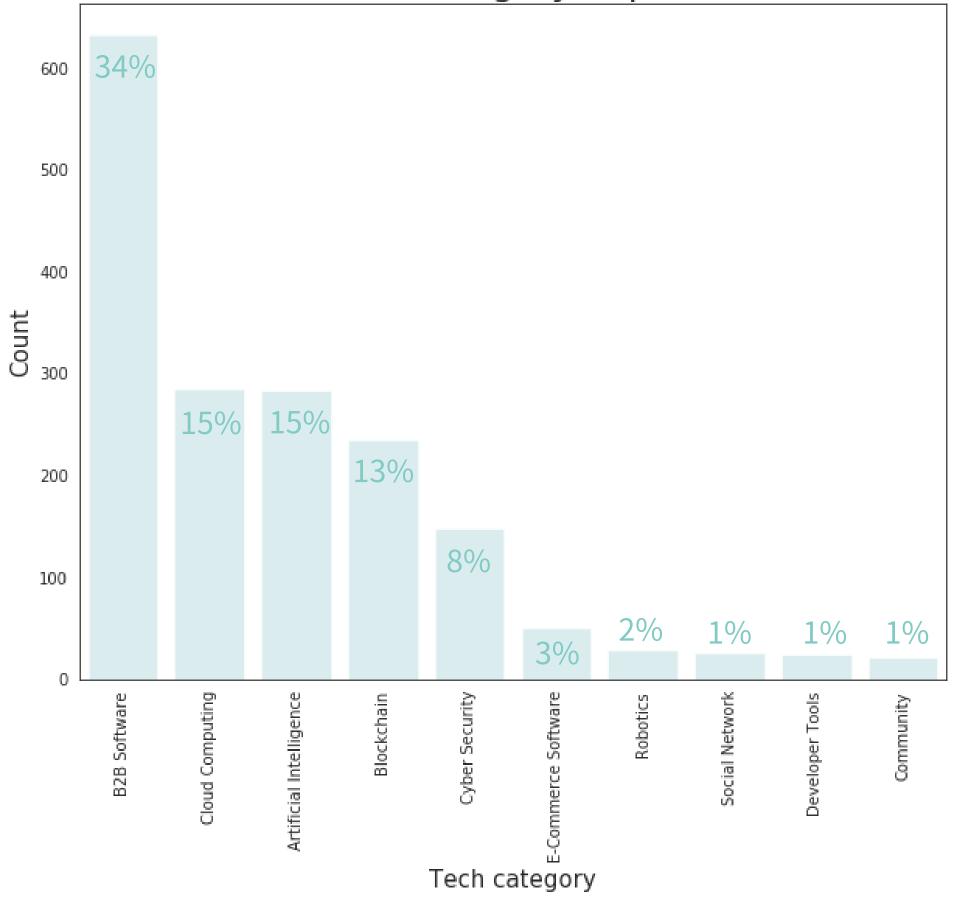




## Tech 범주들을 묶어 Top 10 선별

	index	Field
0	B2B Software	632
1	Cloud Computing	285
2	Artificial Intelligence	283
3	Blockchain	235
4	Cyber Security	147
5	E-Commerce Software	50
6	Robotics	29
7	Social Network	26
8	Developer Tools	24
9	Community	20

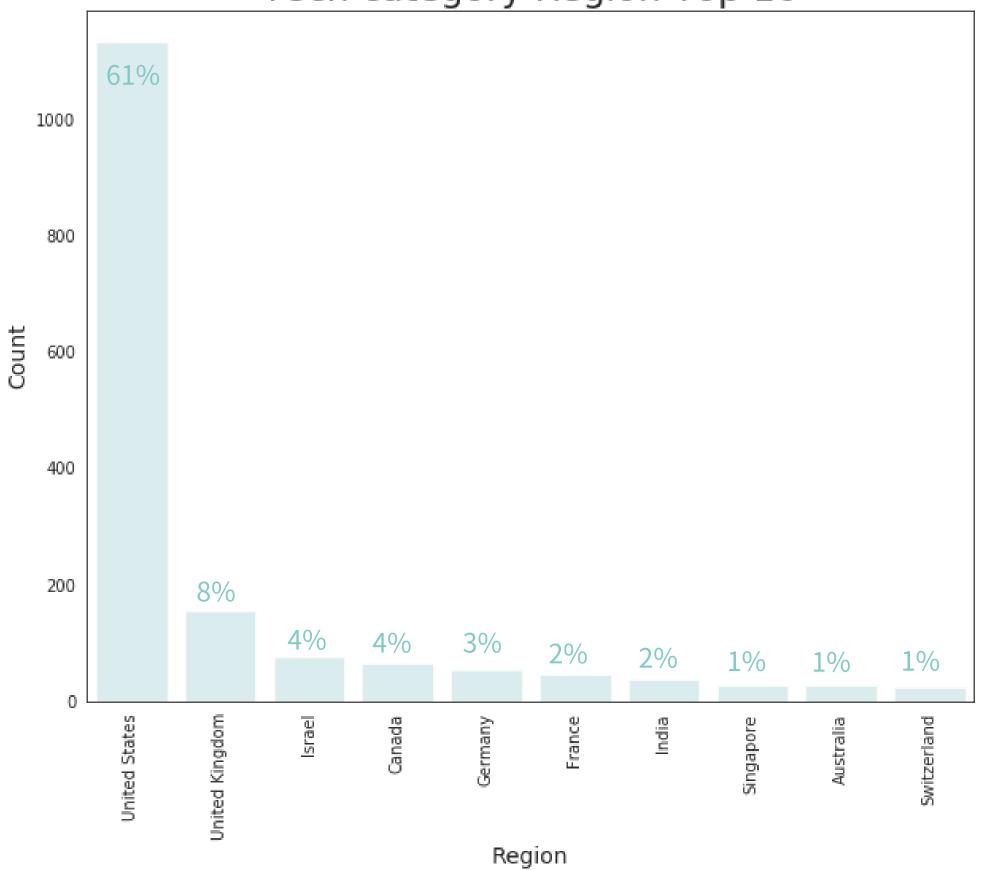
Tech category Top 10



#### Tech 범주들이 빈번한 국가

	index	Region
0	United States	1130
1	United Kingdom	153
2	Israel	75
3	Canada	65
4	Germany	53
5	France	46
6	India	37
7	Singapore	27
8	Australia	26
9	Switzerland	22

#### Tech category Region Top 10

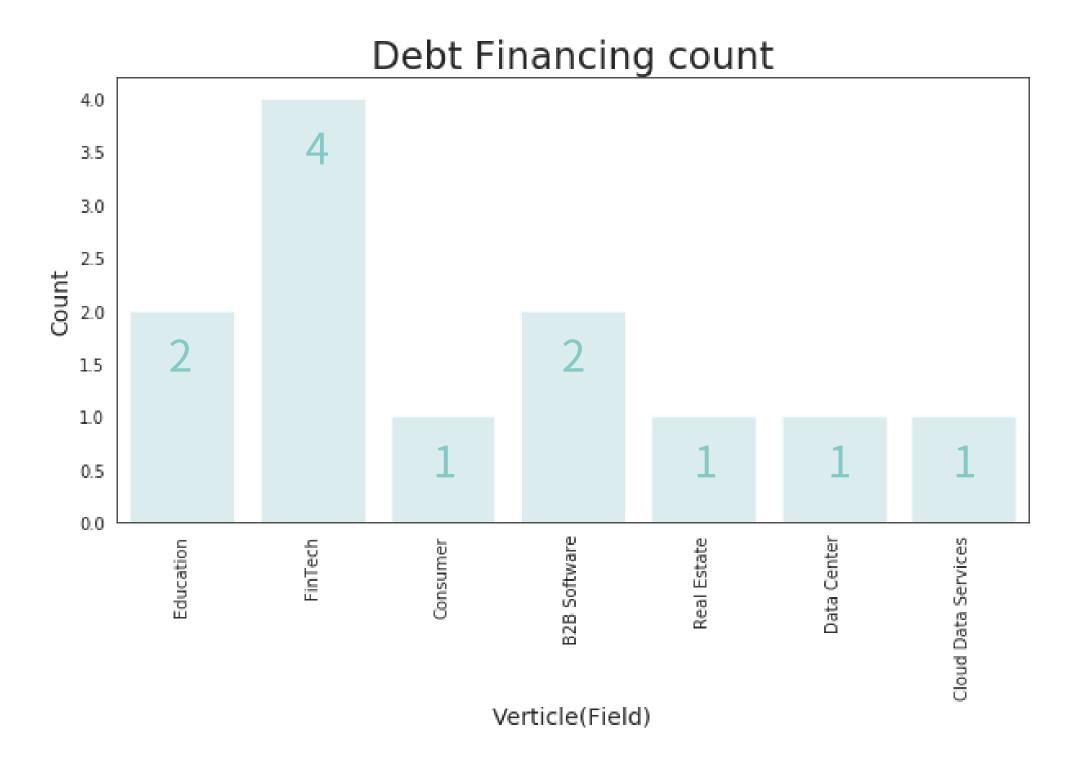


#### **B3.** Data wrangling 3. Funding stage

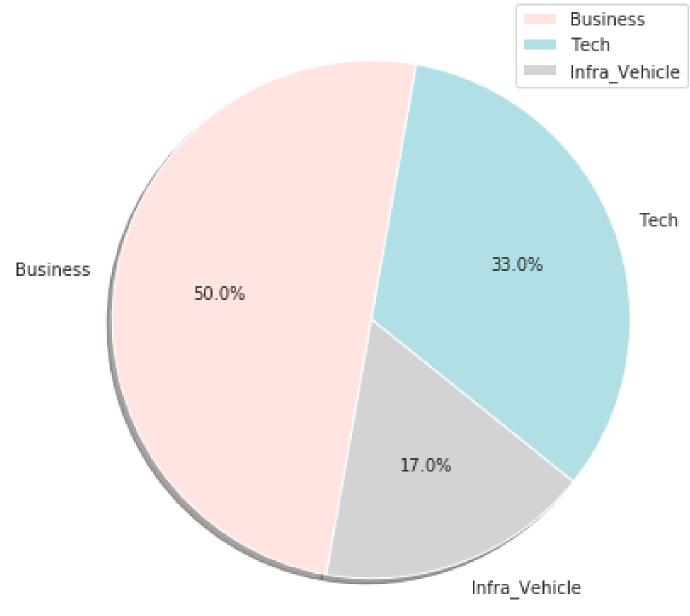
- 20개의 영역을 7개의 범주로 카테고리화하여 invest\_pace feature 생성
- 다중공산성 방지를 위해 Funding\_stage 제거



## **Debt Financing Fund**

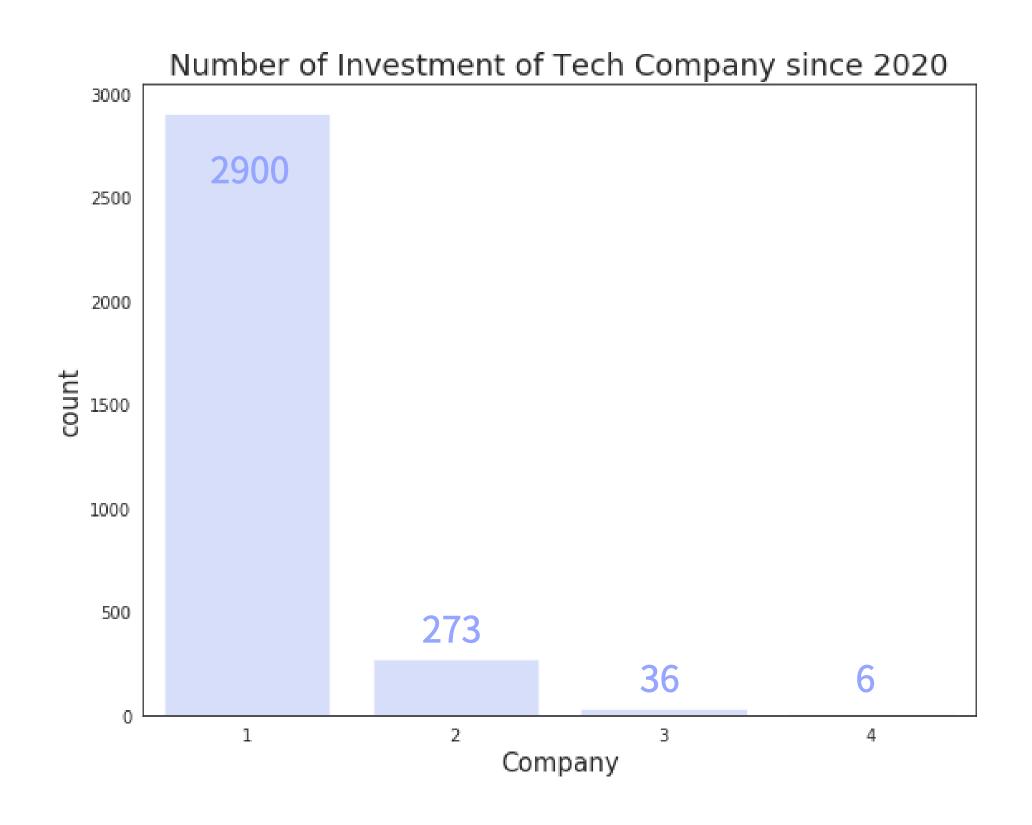


#### Debt Financing count



## + Company: insight

- 대부분의 기업이 한 개 영역에서 투자 받았음을 알 수 있다.



## **Targeting**

Series C 범주의 min 이상

- 국내에서 규모 형성
- 자체 수입으로 기업 영위 가능

#### C1. Target 분포

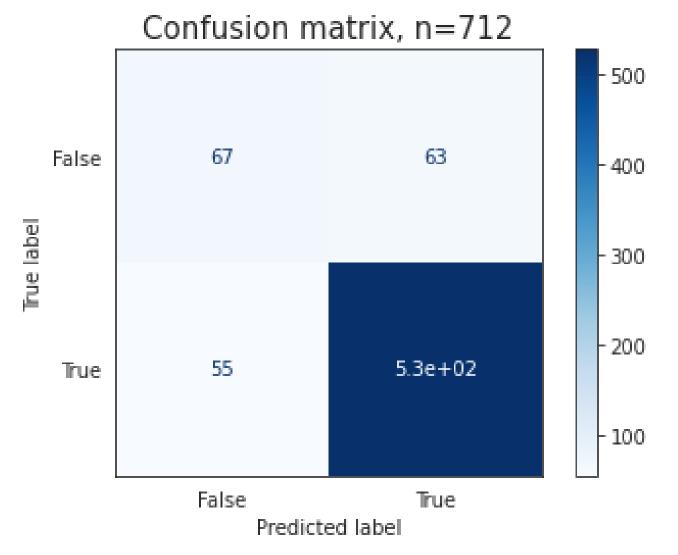
- 다중공산성 방지를 위해 Funding Amount(USD) 항목 제거

True 0.82

False 0.18

#### C2. Data Leakage 여부 확인

- Data Leakage 확인을 위해 데이터셋을 Test, Val set으로 분리
- Oridinal Encoder와 결정트리를 이용하여 파이프라인 형성
- 검증정확도 83%
- 타겟의 분포가 True 82%로 불균형
- Confusion matrix, classification report, roc-auc curve 통해 확인



- TP가 굉장히 높지만, 다른 부분은 높지 않음
- Target의 범주 비율이 높은 비중으로 불균형 했던 것의 결과

from sklearn.metrics import classification\_report
y\_pred\_pre = pipe.predict(X\_val\_pre)
print(classification\_report(y\_val\_pre,y\_pred\_pre))

	precision	recall	f1-score	support
False True	0.55 0.89	0.52 0.91	0.53 0.90	130 582
accuracy macro avg weighted avg	0.72 0.83	0.71 0.83	0.83 0.72 0.83	712 712 712

-정밀도(Precision): True 범주 High, False 범주 Low

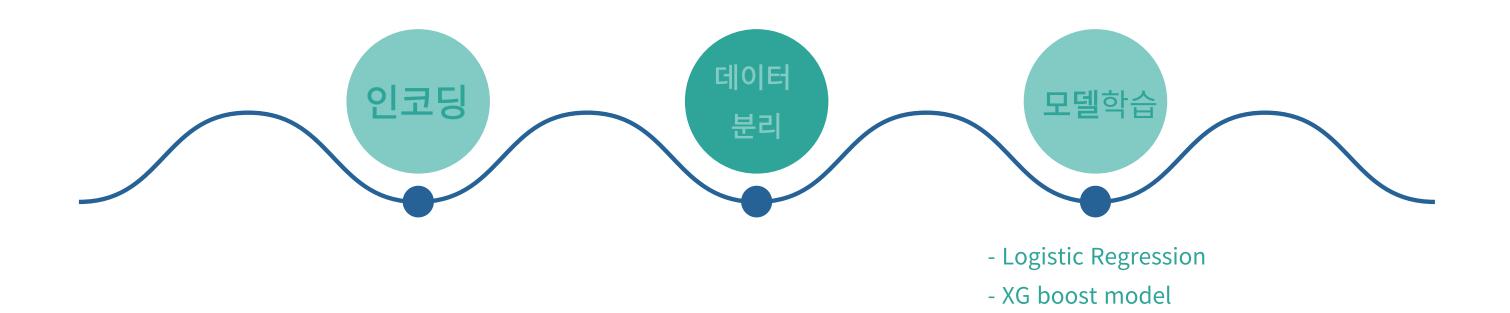
-재현율(Recall) : True 범주 High, False 범주 Low

- 본 모델은 재현율(Recall)이 더 중요

from sklearn.metrics import roc\_auc\_score
auc\_score = roc\_auc\_score(y\_val\_pre, y\_pred\_pre)
auc\_score

0.7104414485857784

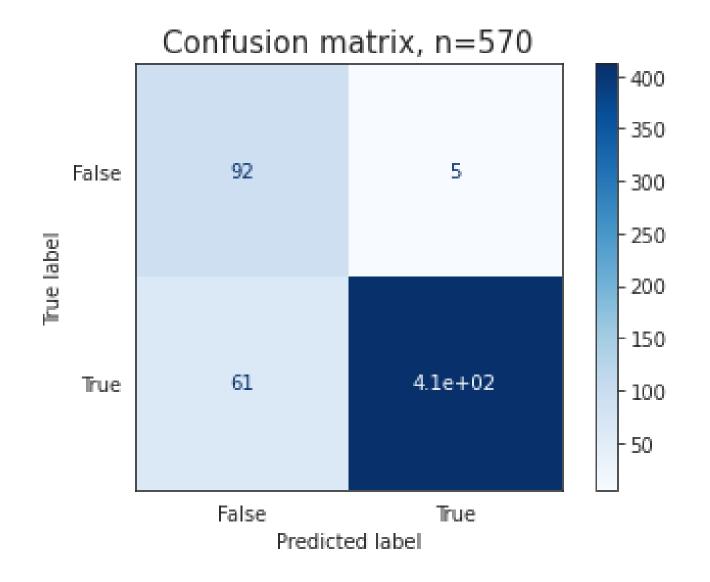
## C3. 모델링



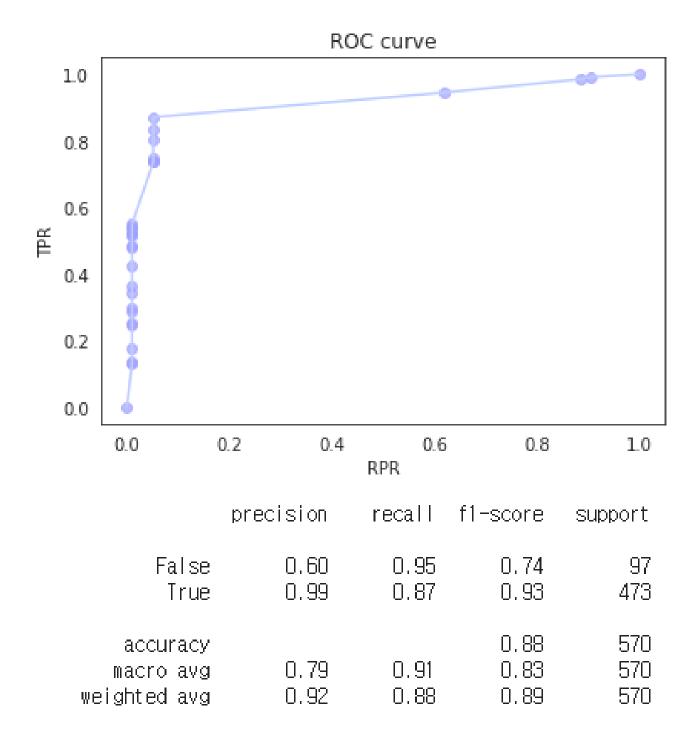
#### Logistic Regression Model & XG boost Model

- 검증 정확도: 88%

- AUC score : 0.91



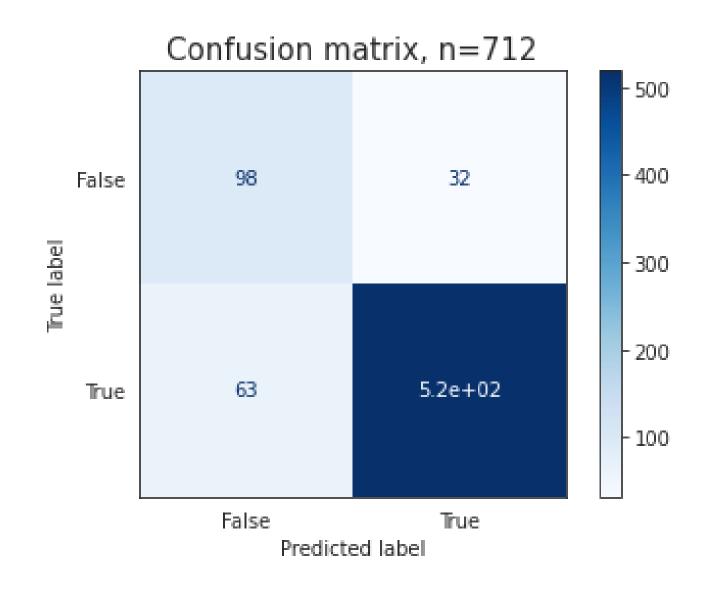
- 두 모델의 결과가 동일했다.
- 하이퍼파라미터를 조절해봤지만 변화가 없으므로 모델 학습을 진행하였다.

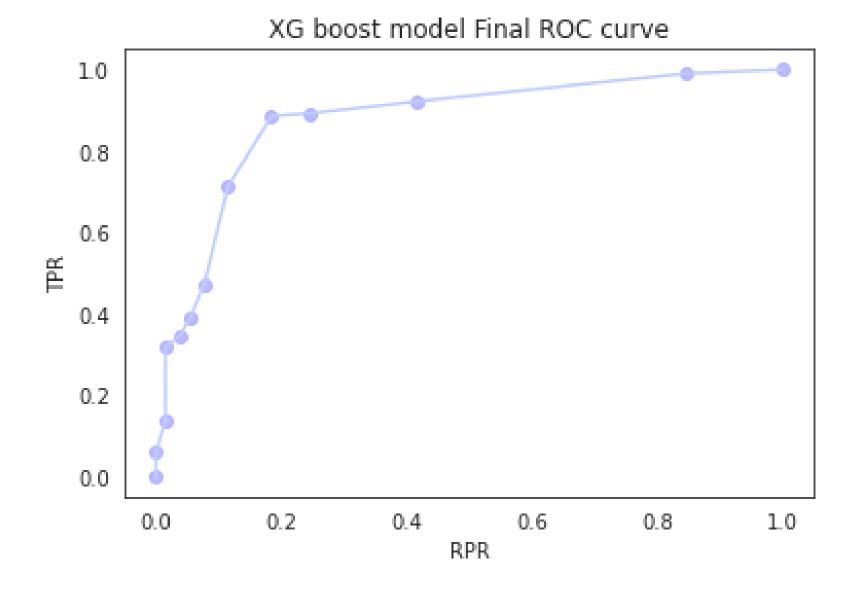


### C4. 최종 모델 학습 (XG boost model)

- 검증 정확도: 86%

- AUC score : 0.875





#### 기준모델 vs. 최종모델

#### 기준모델 (Decision Tree)

		precision	recall	f1-score	support
	False True	0.55 0.89	0.52 0.91	0.53 0.90	130 582
ma	ccuracy cro avg ted avg	0.72 0.83	0.71 0.83	0.83 0.72 0.83	712 712 712

#### 최종모델 (XG boost)

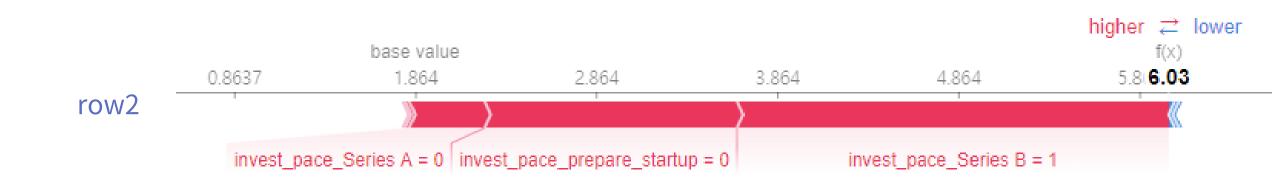
		precision	recall	f1-score	support
	False True	0.60 0.99	0.95 0.87	0.74 0.93	97 473
m	accuracy acro avg hted avg	0.79 0.92	0.91 0.88	0.88 0.83 0.89	570 570 570

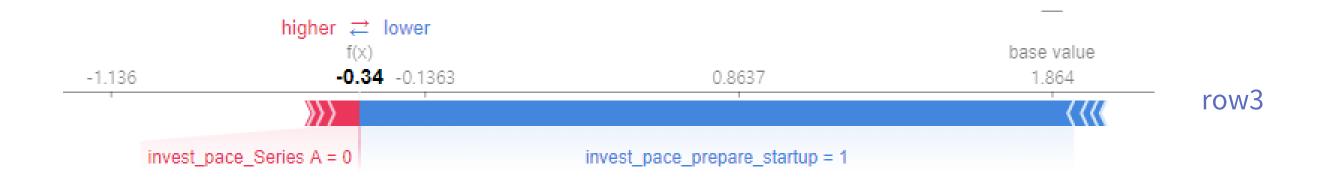
정확도, precision, recall, f1-score 등 모든 영역에서 향상되었다.

#### C5. 모델 해석\_1. SHAP

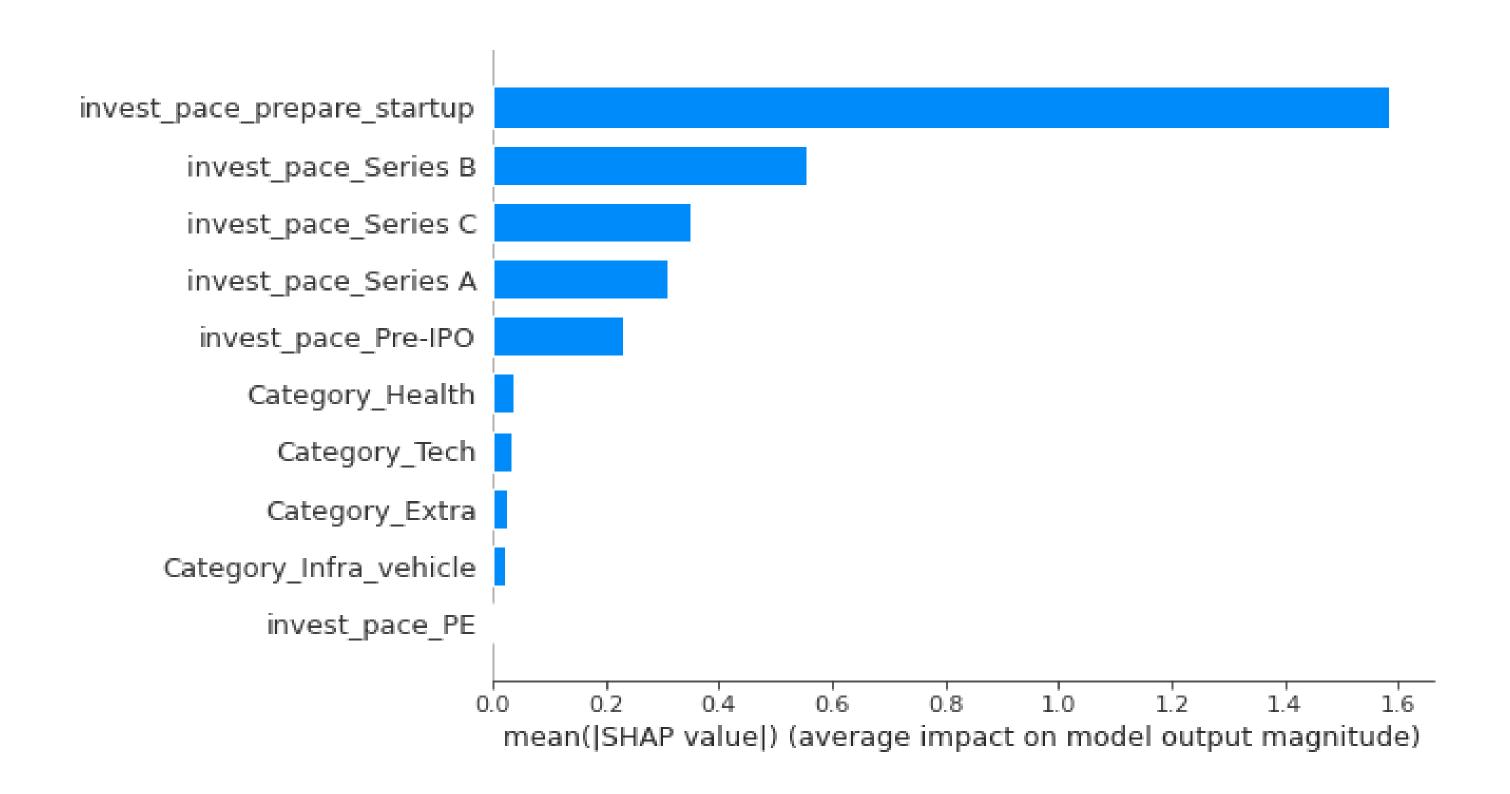








#### 모델 해석\_2. SHAP Value



#### 모델 해석\_3. 예측값 비교

- 예측확률과 실제값을 반영해서 데이터프레임 생성
- 이후 모델에 사용했던 데이터프레임에 합쳐 예측 확인

